Dataset Manager — Roadmap de Funcionalidades

Brainstorm consolidado de candidatas a próximas features do Dataset Manager (pós-migração schema-by-role, PRs 1–10).

Estado atual (já entregue)

• **Toolbar:** Novo / Abrir / Fechar / Salvar / Salvar Como / Enriquecer / Juntar / Dividir / Comparar / Estatísticas / Analisar / Filtrar / Adicionar Coluna

• **Tabela** com edição célula-a-célula, vocabulário fechado renderizado como QComboBox, header context-menu (Propriedades, Remover, Mostrar/Ocultar)

• **Detail panel** da face selecionada

• **Diálogos:** Filter, Stats, Compare, Split, Enrich, Dataset Analysis (hard mining), New Dataset (template), Add Column, Column Properties

• **Schema-by-role** com column_specs na metadata do parquet, vocabulários fechados, alias resolution na leitura

Tema 1 — Higiene de Identidade (alto valor forense)

O core do trabalho do perito é confiar nas identidades. Hoje o Dataset Manager mostra IDs mas não ajuda a auditá-las.

Funcionalidade	Valor	Custo	Notas
Detectar identidades duplicadas (mesma pessoa em 2 labels distintos via clustering por similaridade)	Alto	Médio	Reusa *ComparisonService* ou *HubnessAnalysisService*
Detectar identidades misturadas (mesmo label cobrindo 2+ pessoas — outlier por similaridade intra-classe)	Alto	Médio	Flag forense crítica
Renomear identidade em lote (regex / find-replace + preview de quantos rows mudam)	Médio	Baixo	Operação repetitiva no fluxo atual
Mesclar duas identidades (2 IDs → 1 com confirmação visual)	Médio	Baixo	Resolve falsos positivos do detector

Tema 2 — Visualização de Faces (gap visual)

A tabela mostra texto, mas o forense é visual. Hoje só dá pra ver imagem no detail panel quando clica numa linha.

Funcionalidade	Valor	Custo	Notas
Modo galeria (grid de thumbnails clicáveis, toggle ao lado da tabela)	Alto	Médio	Lazy-load + cache

Funcionalidade	Valor	Custo	Notas
Hover preview (passar mouse no *image_path* mostra mini-thumb)	Médio	Baixo	Tooltip personalizado
Comparar pares de faces (selecionar 2 + side panel lado-a-lado)	Médio	Baixo	Útil pra confirmar sósia

Tema 3 — Integração com V2 (fechamento do fluxo)

Funcionalidade	Valor	Custo	Notas
'Enviar pra Estratégia' (botão na toolbar abre V2 com o dataset já vinculado)	Alto	Baixo	Fluxo um-clique
'Adicionar à Biblioteca Global' (exporta o dataset atual pro *GlobalLibraryStorage*)	Médio	Baixo	Fechamento do Pendrive Paradigm
Re-enriquecer subconjunto (Filtro + 'enriquecer só os filtrados')	Médio	Baixo	Economiza horas em datasets parcialmente enriquecidos

Tema 4 — Schema-by-Role: completar deferidos

Itens que ficaram fora dos PRs 1–10.

Funcionalidade	Valor	Custo	Notas
Drag-reorder colunas (arrastar header pra reordenar)	Médio	Baixo	Item mais pedido em UX de planilha
Filtro com colunas custom (combos dinâmicos no filter_dialog)	Médio	Médio	Reescreve _populate_combos + view
Colunas computadas (fórmula simbólica tipo *yaw_abs = abs(yaw)*, read-only)	Médio	Médio	Define DSL mínimo + executor
Aliases editor (editar aliases na Properties dialog)	Baixo	Baixo	Quase grátis (campo já existe)
categorical_counts genérico (no DatasetStats → custom columns no Compare)	Baixo	Médio	Refactor de DatasetStats + Service + Result

Tema 5 — Higiene de Dados (forense compliance)

Funcionalidade	Valor	Custo	Notas
Verificar paths órfãos (flagar faces cujo image_path não existe em disco)	Alto	Baixo	Detecta corrupção silenciosa

Funcionalidade	Valor	Custo	Notas
Detectar duplicatas exatas (mesmo hash em linhas diferentes)	Médio	Baixo	Higiene básica
Relatório de schema (% NaN por coluna, colunas vazias, inconsistências)	Baixo	Baixo	Lê do column_coverage já persistido
Histórico / audit log (quem mudou o que, quando — chain of custody)	Alto (forense)	Alto	Precisa storage; PR transversal
Export CSV/Excel (com seleção de colunas)	Baixo–Médio	Baixo	Boa UX pra relatórios

Sugestão de priorização (top 3)

Por valor-por-LOC:

- **Detectar identidades duplicadas/misturadas** (Tema 1) — única feature *forense* desta lista; reusa código existente do ComparisonService e HubnessAnalysisService.
- **'Enviar pra Estratégia' + re-enriquecer subconjunto** (Tema 3) — fechamento do fluxo; usuário não precisa mais navegar entre abas.
- **Modo galeria** (Tema 2) — gap visual gritante; once-and-done.

Decisões abertas

- **Foco primário:** higiene de identidade (forense), UX (galeria), ou integração V2?
- **Drag-reorder de colunas é prioridade?** É o item de schema-by-role mais pedido em UX de planilha em geral.
- **Audit log / chain of custody** está no radar do projeto? Se sim, é uma feature transversal grande que merece PR próprio.
- **Existe alguma demanda real do uso atual** que não foi capturada no brainstorm? Tipo 'no caso X eu sempre tenho que fazer Y manualmente'?

Itens explicitamente excluídos do escopo deste roadmap

- **EmbeddingDataset parquet com mesma metadata role-aware** — datasets derivados, não precisam tratamento separado.
- **Refactor de _face_matches_config** em face_dataset.py para ser role-aware — hot-path, não estritamente necessário.

Documento gerado a partir do brainstorm da sessão de planejamento. Versão Markdown editável em *docs/dataset_manager_roadmap.md*.